

Выбор нескольких строк

Вы также можете выбрать несколько строк из DataFrame.

Вот еще несколько строк из DataFrame заказов ShoeFly.com:

id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
54791	Rebecca	Lindsay	RebeccaLindsay57@hotmail.com	clogs	faux-leather	black
53450	Emily	Joyce	EmilyJoyce25@gmail.com	ballet flats	faux-leather	navy
91987	Joyce	Waller	Joyce.Waller@gmail.com	sandals	fabric	black
14437	Justin	Erickson	Justin.Erickson@outlook.com	clogs	faux-leather	red
79357	Andrew	Banks	AB4318@gmail.com	boots	leather	brown
52386	Julie	Marsh	JulieMarsh59@gmail.com	sandals	fabric	black
20487	Thomas	Jensen	TJ5470@gmail.com	clogs	fabric	navy
76971	Janice	Hicks	Janice.Hicks@gmail.com	clogs	faux-leather	navy
21586	Gabriel	Porter	GabrielPorter24@gmail.com	clogs	leather	brown

Вот несколько разных способов выбора нескольких строк:

- `orders.iloc [3: 7]` выберет все строки, начиная с 3-й строки и до 7-й строки, но не включая последнюю (т. е. 3-ю строку, 4-ю строку, 5-ю строку и 6-ю строку).

id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
14437	Justin	Erickson	Justin.Erickson@outlook.com	clogs	faux-leather	red
79357	Andrew	Banks	AB4318@gmail.com	boots	leather	brown
52386	Julie	Marsh	JulieMarsh59@gmail.com	sandals	fabric	black
20487	Thomas	Jensen	TJ5470@gmail.com	clogs	fabric	navy

- `orders.iloc [: 4]` выберет все строки до, но не включая 4-ю строку (т. е. 0-ю, 1-ю, 2-ю и 3-ю строки).

id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
54791	Rebecca	Lindsay	RebeccaLindsay57@hotmail.com	clogs	faux-leather	black
53450	Emily	Joyce	EmilyJoyce25@gmail.com	ballet flats	faux-leather	navy
91987	Joyce	Waller	Joyce.Waller@gmail.com	sandals	fabric	black
14437	Justin	Erickson	Justin.Erickson@outlook.com	clogs	faux-leather	red

- `orders.iloc [-3:]` выберет строки, начиная с 3-й до последней строки включительно.

id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
20487	Thomas	Jensen	TJ5470@gmail.com	clogs	fabric	navy
76971	Janice	Hicks	Janice.Hicks@gmail.com	clogs	faux-leather	navy
21586	Gabriel	Porter	GabrielPorter24@gmail.com	clogs	leather	brown

Задание

1. Один из ваших врачей считает, что в конце весны будет больше посещений клиники.

Напишите команду, которая создаст DataFrame, состоящий из данных за апрель, май и июнь из `df` для всех четырех сайтов (строки с 3 по 6), и сохраните ее в `april_may_june`.

Выведите результат в консоль.

Выбор строки с помощью логики

Вы можете выбрать подмножество DataFrame с помощью логических операторов:

```
df[df.MyColumnName == desired_column_value]
```

У нас есть большой DataFrame с информацией о наших клиентах. Некоторые из множества строк выглядят так:

name	address	phone	age
Martha Jones	123 Main St.	234-567-8910	28
Rose Tyler	456 Maple Ave.	212-867-5309	22
Donna Noble	789 Broadway	949-123-4567	35
Amy Pond	98 West End Ave.	646-555-1234	29
Clara Oswald	54 Columbus Ave.	714-225-1957	31
...	...	...	...

Предположим, мы хотим выбрать все строки, в которых возраст клиента 30. Мы будем использовать:

```
df[df.age == 30]
```

|

В Python `==` — это то, как мы проверяем, точно ли значение равно другому значению.

Мы можем использовать другие логические утверждения, такие как:

- Больше чем, > - здесь мы выбираем все строки, в которых возраст клиента превышает 30:

```
df[df.age > 30]
```

- Меньше, < - здесь мы выбираем все строки, в которых возраст клиента меньше 30:

```
df[df.age < 30]
```

- Не равно, != - Этот фрагмент кода выбирает все строки, в которых имя клиента не Клара Освальд:

```
df[df.name != 'Clara Oswald']
```

Задание

1. Вы собираетесь укомплектовать клинику на январь этого года. Вы хотите знать, сколько посещений было совершено в январе прошлого года, чтобы помочь вам подготовиться.

Создайте переменную january, используя логический оператор, который выбирает строку df, в которой столбец «месяц» равен «январь».

Проверьте результат.

Вы также можете комбинировать несколько логических операторов, если каждое из них заключено в круглые скобки.

Например, предположим, что мы хотим выбрать все строки, в которых возраст клиента меньше 30 или имя клиента «Марта Джонс»:

name	address	phone	age
Martha Jones	123 Main St.	234-567-8910	28
Rose Tyler	456 Maple Ave.	212-867-5309	22
Donna Noble	789 Broadway	949-123-4567	35
Amy Pond	98 West End Ave.	646-555-1234	29
Clara Oswald	54 Columbus Ave.	714-225-1957	31

...

Мы могли бы использовать следующий код:

```
df[(df.age < 30) |  
    (df.name == 'Martha Jones')]
```

|

В Python | означает «или», а & означает «и».

Задание

1. Вы хотите увидеть, как изменилось количество посещений клиники с марта по апрель.

Создайте переменную `march_april`, которая содержит данные за март и апрель. Сделайте это, используя два логических оператора, объединенных с помощью `|`, что означает «или».

Проверить значение переменной `march_april`.

Предположим, мы хотим выбрать строки, в которых имя клиента - «Марта Джонс», «Роуз Тайлер» или «Эми Понд».

name	address	phone	age
Martha Jones	123 Main St.	234-567-8910	28
Rose Tyler	456 Maple Ave.	212-867-5309	22
Donna Noble	789 Broadway	949-123-4567	35
Amy Pond	98 West End Ave.	646-555-1234	29
Clara Oswald	54 Columbus Ave.	714-225-1957	31
...	...	...	...

Мы могли бы использовать команду `isin`, чтобы проверить, что `df.name` является одним из списка значений:

```
df[df.name.isin(['Martha Jones',  
                 'Rose Tyler',  
                 'Amy Pond'])]
```

Задание

1. Другой врач считает, что вы часто ходите в клинику в конце зимы.

Создайте переменную `january_february_march`, содержащую данные за январь, февраль и март. Сделайте это с помощью одного логического оператора с командой `isin`.

Проверьте содержание переменной `january_february_march`.

Обновление индексов

Когда мы выбираем подмножество DataFrame с помощью логики, мы получаем непоследовательные индексы. Это неэлегантно и затрудняет использование `.iloc()`.

Мы можем исправить это с помощью метода `.reset_index()`. Например, вот DataFrame с именем `df` с непоследовательными индексами:

	First Name	Last Name
0	John	Smith
4	Jane	Doe
7	Joe	Schmo

Если мы воспользуемся командой `df.reset_index()`, мы получим новый DataFrame с новым набором индексов:

	index	First Name	Last Name
0	0	John	Smith
1	4	Jane	Doe
2	7	Joe	Schmo

Обратите внимание, что старые индексы были перемещены в новый столбец под названием «индекс». Если вам не нужны эти значения для чего-то особенного, возможно, лучше использовать ключевое слово `drop = True`, чтобы не получить лишний столбец. Если мы запустим команду `df.reset_index(drop = True)`, мы получим новый DataFrame, который выглядит так:

	First Name	Last Name
0	John	Smith
1	Jane	Doe
2	Joe	Schmo

Использование `.reset_index()` вернет новый DataFrame, но обычно мы просто хотим изменить наш существующий DataFrame. Если мы используем ключевое слово `inplace = True`, мы можем просто изменить наш существующий DataFrame.

Задание

1. Изучите код в рабочей области. Обратите внимание, что `df2` — это подмножество строк из `df`.

Введите следующее и нажмите «Выполнить»:

```
print(df2)
```

Обратите внимание, что индексы на `df2` не идут подряд.

```
import pandas as pd
```

```
df = pd.DataFrame([
    ['January', 100, 100, 23, 100],
    ['February', 51, 45, 145, 45],
    ['March', 81, 96, 65, 96],
    ['April', 80, 80, 54, 180],
    ['May', 51, 54, 54, 154],
    ['June', 112, 109, 79, 129]],
    columns=['month', 'clinic_east',
             'clinic_north', 'clinic_south',
             'clinic_west']
)

df2 = df.loc[[1, 3, 5]]
```

2. Создайте новый DataFrame с именем df3, сбросив индексы на df2 (не используйте inplace или drop). Изменился ли df2 после того, как вы выполнили эту команду?
3. Сбросьте индексы df2, используя ключевое слово inplace = True и drop = True. Изменились ли индексы df2? Чем df2 отличается от df3?

Заключение

Вы прошли урок! Вы только что узнали основы работы с одной таблицей в Pandas, в том числе:

- Создать таблицу с нуля
- Загрузка данных из другого файла
- Выбор определенных строк или столбцов таблицы

Задание

1. В этом примере вы будете аналитиком данных в ShoeFly.com, вымышленном интернет-магазине обуви. Вы видели эти данные; теперь ваша очередь работать с ним!

Загрузите данные из shoefly.csv в переменные orders.

2. Проверьте первые 5 строк данных.
3. Ваш отдел маркетинга хочет разослать письмо всем, кто заказал обувь!

Выберите все адреса электронной почты из столбца «Электронная почта» и сохраните их в переменной с именем «emails».

4. Фрэнсис Палмер утверждает, что ее заказ был неправильным. Что заказывала Фрэнсис Палмер?

Используйте логику, чтобы выбрать эту строку заказов и сохранить ее в переменной `frances_palmer`.

5. Нам нужны отзывы покупателей о нашей удобной обуви. Выберите все заказы для параметра `shoe_type`: сабо, ботинки и балетки и сохраните их в переменной `comfy_shoes`.