

Импорт модуля Pandas

Pandas - это модуль Python для работы с табличными данными (т.е. данными в таблице со строками и столбцами). Табличные данные имеют те же функции, что и SQL или Excel, но Pandas добавляет мощь Python.

Чтобы получить доступ к модулю Pandas, нам нужно установить модуль, а затем импортировать его в файл Python.

Модуль pandas обычно импортируется в начало файла Python под псевдонимом pd.

```
import pandas as pd
```

В этом уроке вы изучите основы работы с одной таблицей в Pandas, например:

- Создать таблицу с нуля
- Загрузка данных из другого файла
- Выбор определенных строк или столбцов таблицы

Что мы можем делать с Pandas?

В этом примере мы будем работать с данными ShoeFly.com, вымышленного интернет-магазина обуви.

```
In [1]: # Before we analyze anything, we need to import pandas  
import pandas as pd
```

Мы можем загружать данные в Pandas из файла csv (переменные, разделенные запятыми). Эти данные представляют собой покупки на ShoeFly.com.

```
In [2]: df = pd.read_csv('shoefly_orders.csv')
```

Давайте исследуем первые 10 строк наших данных!

```
In [3]: df.head(10)
```

Out[3]:

	id	first_name	last_name	email	shoe_type	shoe_material
0	54791	Rebecca	Lindsay	RebeccaLindsay57@hotmail.com	clogs	faux-leather
1	53450	Emily	Joyce	EmilyJoyce25@gmail.com	ballet flats	faux-leather
2	91987	Joyce	Waller	Joyce.Waller@gmail.com	sandals	fabric
3	14437	Justin	Erickson	Justin.Erickson@outlook.com	clogs	faux-leather
4	79357	Andrew	Banks	AB4318@gmail.com	boots	leather
5	52386	Julie	Marsh	JulieMarsh59@gmail.com	sandals	fabric
6	20487	Thomas	Jensen	TJ5470@gmail.com	clogs	fabric
7	76971	Janice	Hicks	Janice.Hicks@gmail.com	clogs	faux-leather
8	21586	Gabriel	Porter	GabrielPorter24@gmail.com	clogs	leather
9	62083	Frances	Palmer	FrancesPalmer50@gmail.com	wedges	leather

Выберем всех, кто заказал черные босоножки.

```
In [4]: df[(df.shoe_type == 'sandals') & (df.shoe_color == 'black')]
```

Out[4]:

	id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
2	91987	Joyce	Waller	Joyce.Waller@gmail.com	sandals	fabric	black
5	52386	Julie	Marsh	JulieMarsh59@gmail.com	sandals	fabric	black

Посмотрим, что заказала Сюзен Деннис.

```
In [5]: df[(df.first_name == 'Susan') & (df.last_name == 'Dennis')]
```

Out[5]:

	id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
12	45832	Susan	Dennis	SusanDennis58@gmail.com	ballet flats	fabric	white

Похоже, Сюзан заказала белые тканевые балетки!

Создание DataFrame I

DataFrame - это объект, который хранит данные в виде строк и столбцов. Вы можете представить DataFrame как электронную таблицу или как таблицу SQL. Вы можете вручную создать DataFrame или заполнить его данными из CSV, электронной таблицы Excel или SQL-запроса.

DataFrames имеют строки и столбцы. У каждого столбца есть имя, которое представляет собой строку. Каждая строка имеет индекс, который является целым числом. DataFrames могут содержать множество различных типов данных: строки, целые числа, числа с плавающей запятой, кортежи и т. Д.

Вы можете передать словарь в `pd.DataFrame()`. Каждый ключ - это имя столбца, а каждое значение - это список значений столбца. Все столбцы должны быть одинаковой длины, иначе вы получите сообщение об ошибке. Вот пример:

```
df1 = pd.DataFrame({
    'name': ['John Smith', 'Jane Doe', 'Joe Schmo'],
    'address': ['123 Main St.', '456 Maple Ave.', '789
Broadway'],
    'age': [34, 28, 51]
})
```

Эта команда создает DataFrame с именем df1, который выглядит следующим образом:

address	age	name
123 Main St.	34	John Smith
456 Maple Ave.	28	Jane Doe
789 Broadway	51	Joe Schmo

Обратите внимание, что столбцы будут располагаться в алфавитном порядке, поскольку словари не имеют внутреннего порядка расположения столбцов.

Задание

1. У вас есть интернет-магазин одежды под названием Panda's Wizard. Вам нужен DataFrame, содержащий информацию о ваших продуктах.

Создайте DataFrame со следующими данными, которые вам отправил менеджер по запасам:

Product ID	Product Name	Color
1	t-shirt	blue
2	t-shirt	green
3	skirt	red
4	skirt	black

Создание DataFrame II

Вы также можете добавлять данные с помощью списков.

Например, вы можете передать список списков, каждый из которых представляет собой строку данных. Используйте столбцы аргумента ключевого слова, чтобы передать список имен столбцов.

```
df2 = pd.DataFrame([
    ['John Smith', '123 Main St.', 34],
    ['Jane Doe', '456 Maple Ave.', 28],
    ['Joe Schmo', '789 Broadway', 51]
],
    columns=['name', 'address', 'age'])
```

Т

Эта команда создает DataFrame df2, который выглядит следующим образом:

name	address	age
John Smith	123 Main St.	34
Jane Doe	456 Maple Ave.	28
Joe Schmo	789 Broadway	51

В этом примере мы смогли контролировать порядок столбцов, потому что использовали списки.

Задание

1. Вы управляете сетью магазинов лавашей под названием Pita Power. Вы хотите создать DataFrame с информацией о различных местоположениях ваших магазинов.

Используйте список списков для создания DataFrame со следующими данными:

Store ID	Location	Number of Employees
1	San Diego	100
2	Los Angeles	120
3	San Francisco	90
4	Sacramento	115

Переменные, разделенные запятыми (CSV)

Теперь мы знаем, как создать собственный DataFrame. Однако в большинстве случаев мы будем работать с уже существующими наборами данных. Одним из наиболее распространенных форматов больших наборов данных является CSV.

CSV (значения, разделенные запятыми) - это текстовый формат электронной таблицы. Вы можете найти CSV во многих местах:

Наборы данных в Интернете (вот пример с сайта data.gov)

Экспорт из Excel или Google Таблиц

Экспорт из SQL

Первая строка CSV содержит заголовки столбцов. Все последующие строки содержат значения. Заголовок каждого столбца и каждая переменная разделяются запятыми:

```
column1,column2,column3
value1,value2,value3
```

T

Этот пример CSV представляет собой следующую таблицу:

column1	column2	column3
value1	value2	value3

Задание

1. Вы управляете магазином кексов и хотите записать все предлагаемые кексы.

Запишите следующие данные в формате CSV в файл `cupcakes.csv`.

name	cake_flavor	frosting_flavor	topping
Chocolate Cake	chocolate	chocolate	chocolate shavings
Birthday Cake	vanilla	vanilla	rainbow sprinkles
Carrot Cake	carrot	cream cheese	almonds

Загрузка и сохранение CSV

Когда у вас есть данные в CSV, вы можете загрузить их в DataFrame в Pandas, используя `.read_csv()`:

```
pd.read_csv('my-csv-file.csv')
```

В приведенном выше примере вызывается метод `.read_csv()`. CSV-файл с именем `my-csv-file` передается в качестве аргумента.

Мы также можем сохранить данные в CSV, используя `.to_csv()`.

```
df.to_csv('new-csv-file.csv')
```

В приведенном выше примере метод `.to_csv()` вызывается в `df` (который представляет объект DataFrame). Имя CSV-файла передается в качестве аргумента (`new-csv-file.csv`). По умолчанию этот метод сохранит файл CSV в вашем текущем каталоге.

Задание

1. Вы работаете в округе Whoville и только что получили CSV-файл с данными о различных городах вашего округа. Прочтите CSV-файл `sample.csv` в переменной с именем `df`, чтобы узнать больше о городах.
2. Давайте проверим CSV.
Введите `print(df)` в следующей строке и запустите свой код. Какие данные вы получили?

Проверить фрейм данных

Когда мы загружаем новый DataFrame из CSV, мы хотим знать, как он выглядит.

Если это небольшой DataFrame, вы можете отобразить его, набрав `print(df)`.

Если это более крупный DataFrame, полезно иметь возможность проверять несколько элементов, не просматривая весь DataFrame.

Метод `.head()` дает первые 5 строк DataFrame. Если вы хотите увидеть больше строк, вы можете передать позиционный аргумент `n`. Например, `df.head(10)` покажет первые 10 строк.

Задание

1. Вы работаете в голливудской студии, пытаясь использовать данные, чтобы предсказать следующий большой успех. Загрузите CSV `imdb.csv` в переменную с именем `df`, чтобы вы могли узнать о популярных фильмах за последние 90 лет.
2. Давайте узнаем об этих фильмах.
Вставьте следующий код

```
print(df.head())
```

3. Что именно находится в этом наборе данных?
Вставьте следующий код

```
print(df.info())
```

Выбрать столбцы

Теперь мы знаем, как создавать и загружать данные. Давайте выберем части этих наборов данных, которые интересны или важны для нашего анализа.

Предположим, у вас есть DataFrame с именем `customers`, который содержит возраст ваших клиентов:

name	age
Rebecca Erikson	35
Thomas Roberson	28
Diane Ochoa	42
...	...

Возможно, вы хотите взять среднее значение или построить гистограмму возрастов. Для выполнения любой из этих задач вам нужно будет выбрать столбец.

Есть два возможных синтаксиса для выбора всех значений из столбца:

Выберите столбец, как если бы вы выбирали значение из словаря с помощью ключа. В нашем примере мы бы набрали клиентов `['age']`, чтобы выбрать возраст.

Если имя столбца соответствует всем правилам для имени переменной (не начинается с числа, не содержит пробелов или специальных символов и т. Д.), Вы можете выбрать его, используя следующую запись: `df.MySecondColumn`. В нашем примере мы должны ввести `customers.age`.

Задание

1. DataFrame df представляет данные, собранные четырьмя клиниками, управляемыми одной организацией. Каждая строка представляет месяца с января по июнь и показывает количество посещений, сделанных в четырех разных клиниках.

Вы хотите проанализировать, что происходит на севере. Создайте переменную с именем clinic_north, которая содержит ТОЛЬКО данные из столбца clinic_north.

```
import codecademylib3
import pandas as pd

df = pd.DataFrame([
    ['January', 100, 100, 23, 100],
    ['February', 51, 45, 145, 45],
    ['March', 81, 96, 65, 96],
    ['April', 80, 80, 54, 180],
    ['May', 51, 54, 54, 154],
    ['June', 112, 109, 79, 129]],
    columns=['month', 'clinic_east',
             'clinic_north', 'clinic_south',
             'clinic_west']
)
```

2. Что именно вы выбрали?

После создания переменной введите команду:

```
print(type(clinic_north))
```

чтобы узнать, какой тип данных вы создали.

Чем это отличается от того, что вы получите, если наберете следующее?

```
print(type(df))
```

Выбор нескольких столбцов

Если у вас DataFrame большего размера, вы можете выбрать всего несколько столбцов.

id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
54791	Rebecca	Lindsay	RebeccaLindsay57@hotmail.com	clogs	faux-leather	black
53450	Emily	Joyce	EmilyJoyce25@gmail.com	ballet flats	faux-leather	navy
91987	Joyce	Waller	Joyce.Waller@gmail.com	sandals	fabric	black

14437 Justin Erickson Justin.Erickson@outlook.com clogs faux-leather red

Например, вернемся к DataFrame заказов с ShoeFly.com:

Возможно, нас просто интересуют фамилия и адрес электронной почты клиента. Нам нужен DataFrame, подобный этому:

last_name	email
Lindsay	RebeccaLindsay57@hotmail.com
Joyce	EmilyJoyce25@gmail.com
Waller	Joyce.Waller@gmail.com
Erickson	Justin.Erickson@outlook.com

Чтобы выбрать два или более столбца из DataFrame, мы используем список имен столбцов. Чтобы создать DataFrame, показанный выше, мы будем использовать:

```
new_df = orders[['last_name', 'email']]
```

Примечание. Убедитесь, что у вас есть двойные скобки ([][]), иначе эта команда не сработает!

Задание

1. Теперь вы хотите сравнить посещения северной и южной клиник.

Создайте переменную с именем clinic_north_south, которая содержит ТОЛЬКО данные из столбцов clinic_north и clinic_south.

2. Когда мы выбираем несколько столбцов, получаем ли мы серию или DataFrame?

После того, как вы создали переменную, введите команду:

```
print(type(clinic_north_south))
```

чтобы узнать, какой тип данных вы создали.

Чем это отличается от того, что произошло в предыдущем упражнении?

Выбрать строки

Давайте еще раз рассмотрим наши заказы на ShoeFly.com:

id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
54791	Rebecca	Lindsay	RebeccaLindsay57@hotmail.com	clogs	faux-leather	black
53450	Emily	James	EmilyJames25@gmail.com	ballet flats	faux-leather	navy
91987	Joyce	Waller	Joyce.Waller@gmail.com	sandals	fabric	black

id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
14437	Justin	Erickson	Justin.Erickson@outlook.com	clogs	faux-leather	red
...						

Возможно, наш отдел обслуживания клиентов только что получил сообщение от Джойс Уоллер, поэтому мы хотим точно знать, что она заказывала. Мы хотим выбрать эту единственную строку данных.

DataFrames имеют нулевой индекс, что означает, что мы начинаем с 0-й строки и отсчитываем оттуда. Заказ Джойс Уоллер - это 2-я строка.

Выбираем его с помощью следующей команды:

```
orders.iloc[2]
```

Когда мы выбираем одну строку, результатом является серия (точно так же, как когда мы выбираем один столбец).

Задание

1. Вы готовитесь укомплектовать клинику на март этого года. Вы хотите знать, сколько посещений было совершено в марте прошлого года, чтобы помочь вам подготовиться.

Напишите команду, которая создаст серию, состоящую из данных March из df со всех четырех клиник, и сохранит ее в переменной march.

Выбор нескольких строк

Вы также можете выбрать несколько строк из DataFrame.

Вот еще несколько строк из DataFrame заказов ShoeFly.com:

id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
54791	Rebecca	Lindsay	RebeccaLindsay57@hotmail.com	clogs	faux-leather	black
53450	Emily	Joyce	EmilyJoyce25@gmail.com	ballet flats	faux-leather	navy
91987	Joyce	Waller	Joyce.Waller@gmail.com	sandals	fabric	black
14437	Justin	Erickson	Justin.Erickson@outlook.com	clogs	faux-leather	red
79357	Andrew	Banks	AB4318@gmail.com	boots	leather	brown
52386	Julie	Marsh	JulieMarsh59@gmail.com	sandals	fabric	black
20487	Thomas	Jensen	TJ5470@gmail.com	clogs	fabric	navy
76971	Janice	Hicks	Janice.Hicks@gmail.com	clogs	faux-leather	navy
21586	Gabriel	Porter	GabrielPorter24@gmail.com	clogs	leather	brown

Вот несколько разных способов выбора нескольких строк:

- `orders.iloc [3: 7]` выберет все строки, начиная с 3-й строки и до 7-й строки, но не включая последнюю (т. е. 3-ю строку, 4-ю строку, 5-ю строку и 6-ю строку).

id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
14437	Justin	Erickson	Justin.Erickson@outlook.com	clogs	faux-leather	red
79357	Andrew	Banks	AB4318@gmail.com	boots	leather	brown
52386	Julie	Marsh	JulieMarsh59@gmail.com	sandals	fabric	black
20487	Thomas	Jensen	TJ5470@gmail.com	clogs	fabric	navy

- `orders.iloc [: 4]` выберет все строки до, но не включая 4-ю строку (т. е. 0-ю, 1-ю, 2-ю и 3-ю строки).

id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
54791	Rebecca	Lindsay	RebeccaLindsay57@hotmail.com	clogs	faux-leather	black
53450	Emily	Joyce	EmilyJoyce25@gmail.com	ballet flats	faux-leather	navy
91987	Joyce	Waller	Joyce.Waller@gmail.com	sandals	fabric	black
14437	Justin	Erickson	Justin.Erickson@outlook.com	clogs	faux-leather	red

- `orders.iloc [-3:]` выберет строки, начиная с 3-й до последней строки включительно.

id	first_name	last_name	email	shoe_type	shoe_material	shoe_color
20487	Thomas	Jensen	TJ5470@gmail.com	clogs	fabric	navy
76971	Janice	Hicks	Janice.Hicks@gmail.com	clogs	faux-leather	navy
21586	Gabriel	Porter	GabrielPorter24@gmail.com	clogs	leather	brown